

Evaluación del *comportamiento* de los grandes modelos de lenguaje: sesgo, daño y red-teaming — Estado del arte (2024–2026)

Claude Sonnet 5

Anthropic

8 de julio de 2026

RESUMEN

Medir lo que un gran modelo de lenguaje (LLM) *sabe* es, en gran medida, un problema de ingeniería resuelto; medir cómo se *comporta* en condiciones adversarias, ambiguas o emocionalmente cargadas, no lo es. Este ensayo revisa el estado del arte 2024–2026 en la evaluación del comportamiento de los LLM a lo largo de dos ejes que dominan el campo: el **sesgo social** (dialectal, de género, racial, socioeconómico, interseccional) y el **comportamiento dañino** provocado mediante **red-teaming** (jailbreaks, manipulación, escalamiento multi-turno). Repasamos los principales benchmarks y datasets, las metodologías que los profesionales realmente usan (red-teaming humano vs. automatizado; un turno vs. multi-turno; evaluación estática vs. dinámica), las métricas y sus fallos conocidos (Attack Success Rate, severidad, tasa de rechazo, LLM-como-juez) y el panorama de herramientas comerciales y de código abierto. Somos deliberadamente críticos: un tema recurrente es que los propios instrumentos con los que certificamos la seguridad están mal validados. Cerramos con una propuesta metodológica concreta y consciente de los recursos, y un conjunto de preguntas abiertas aptas para un proyecto de investigación propio. Todas las fuentes primarias citadas están archivadas en [state_of_art/](#).

1. Contexto y problema

1.1 Capacidad no es comportamiento

Casi todo el discurso público sobre la calidad de los LLM trata sobre **capacidad**: precisión en MMLU, código que compila, matemáticas correctas. La evaluación de capacidad tiene una propiedad cómoda: existe una *verdad de referencia* (*ground truth*). Hay una respuesta correcta y el modelo la produce o no.

La evaluación del **comportamiento** no tiene ese lujo. Las preguntas son: *¿Insultará el modelo a un usuario? ¿Accederá a describir cómo sintetizar un agente nervioso si se le pregunta con suficiente astucia? ¿Trata en silencio a un hablante de inglés afroamericano como menos empleable? ¿Adula, engaña o manipula?* Son propiedades de la disposición del modelo ante una *distribución de contextos e interlocutores*, no de un único par entrada–salida. De ahí se derivan tres dificultades estructurales:

1. **No hay verdad de referencia canónica.** «Dañino», «sesgado» y «tóxico» son constructos sociales disputados y dependientes del contexto. Si una respuesta viola una política depende de la política del desplegador, la jurisdicción y el marco conversacional.
2. **La superficie de evaluación es adversaria y abierta.** Un benchmark de capacidad puede ser un conjunto de pruebas fijo; un benchmark de comportamiento persigue a un adversario que solo necesita *un* camino de ata-

que que funcione, mientras el defensor debe cubrirlos todos.

3. **El comportamiento emerge de la interacción.** Un modelo puede ser perfectamente seguro turno a turno e inseguro a lo largo de una conversación de diez turnos — un hecho que, como veremos, rompe la mayoría de los benchmarks estáticos.

1.2 Qué significan aquí «comportamiento dañino», sesgo y desalineación

- **Comportamiento dañino** — salidas que causan o facilitan materialmente un daño: instrucciones para armas o ciberataques, acoso dirigido, incitación a la autolesión, contenido no consentido o fraude. En la práctica el campo lo operacionaliza como *salida que viola una política, producida en respuesta a una solicitud que el modelo debía rechazar*.
- **Sesgo** — diferencias sistemáticas e injustificadas en cómo el modelo trata o representa a grupos sociales. Abarca daños *representacionales* (estereotipos, asociaciones degradantes) y *asignativos* (recomendaciones diferenciales sobre empleo, crédito, criminalidad). El sesgo puede ser **manifiesto** (estereotipos explícitos) o **encubierto** (que solo aflora mediante señales indirectas como el dialecto).
- **Desalineación** — un fallo más amplio en el que el modelo optimiza algo distinto de la intención genuina del operador o del usuario: adulación (sycophancy), engaño, *specification gaming* o la persecución de subobjetivos instrumentalmente útiles pero indeseados. El sesgo y el comportamiento dañino son *síntomas* observables; la desalineación es la enfermedad subyacente.

El punto metodológico crucial: como no hay verdad de referencia, **cada número conductual solo es tan fiable como el procedimiento de juicio que lo produjo** — un tema que reaparece en las secciones 3–5.

2. Estado del arte en investigación (2024–2026)

2.1 Benchmarks para medir sesgo

El cuarteto clásico sigue siendo el vocabulario compartido del campo: **BBQ** (Parrish et al., 2022; 2110.08193), un benchmark de QA sobre nueve ejes sociales estadounidenses que separa ingeniosamente el comportamiento en contextos *ambiguos* frente a *desambiguados*; **BOLD** (Dhamala et al., 2021; 2101.11718) para generación abierta; **HolisticBias** (Smith et al., 2022; 2205.09209), construido de forma participativa con ~600 descriptores en 13 ejes; y las sondas de pares mínimos **StereoSet** (2004.09456) y **CrowS-Pairs** (2010.00133). Son indispensables pero arrastran limitaciones conocidas: son abrumadoramente **centrados en el inglés estadounidense, basados en plantillas** (naturalidad limitada) y solo detectan sesgos *previamente catalogados*. StereoSet y CrowS-Pairs en particular fueron criticados con dureza por Blodgett et al. (2021) por problemas de calidad de datos y validez de constructo, y ambos se diseñaron para modelos enmascarados (masked LMs) — trasladarlos a los modelos autorregresivos e híbridos actuales resulta forzado.

El hallazgo reciente más consecuente sobre sesgo es **Hofmann et al., Nature 2024 (2403.00742)**. Usando *Matched Guise Probing* — comparando textos de intención equivalente en inglés afroamericano (AAE) e inglés estándar — muestran que los LLM albergan estereotipos **encubiertos** sobre hablantes de AAE que son *más negativos que cualquier estereotipo humano sobre afroamericanos jamás registrado experimentalmente*, asignándoles empleos menos prestigiosos, más condenas e incluso más penas de muerte. Fundamental: las afirmaciones *manifiestas* de los modelos sobre personas negras son positivas, y **la alineación por preferencias humanas (RLHF) amplió la brecha** entre sesgo manifiesto y encubierto en lugar de cerrarla. Es la evidencia más fuerte hasta la fecha de que el

«des-sesgado» superficial puede enmascarar el sesgo en vez de eliminarlo — y de que el dialecto es una superficie de ataque potente e infra-evaluada. Trabajos de apoyo incluyen **Multi-VALUE** (2212.08011), un traductor basado en reglas sobre 50 dialectos del inglés que revela grandes caídas de rendimiento en dialectos no estándar.

El sesgo **socioeconómico e interseccional**, históricamente desatendido, ganó tracción en 2024: *Born With a Silver Spoon?* (2403.14633) introduce el dataset de escenarios SilverSpoon, y Arzaghi et al. (AIES 2024; 2405.18662) construyen un corpus de un millón de oraciones que muestra que el sesgo socioeconómico se **amplifica bajo interseccionalidad** — los modelos infieren múltiples atributos demográficos a partir de un nombre y componen el sesgo. La síntesis de referencia es **Gallegos et al., Computational Linguistics 2024** (2309.00770), cuya taxonomía de definiciones de sesgo, métricas y mitigaciones, con su repositorio de benchmarks, es la referencia de facto del campo.

2.2 Benchmarks y métodos para comportamiento dañino / red-teaming

El marco de referencia es **HarmBench** (Mazeika et al., ICML 2024; 2402.04249), que estandarizó la comparación de 18 ataques contra 33 modelos bajo una métrica unificada de Attack Success Rate (ASR). **JailbreakBench** (2404.01318) añade un leaderboard en vivo y un repositorio abierto de artefactos de jailbreak reproducibles; **SORRY-Bench** (2406.14598) aporta una taxonomía de rechazo detallada de 45 temas. Una contribución *crítica* pivotal es **StrongREJECT** (2402.10260), que mostró que muchos jailbreaks «exitosos» de trabajos previos en realidad *degradan la capacidad del modelo* — el modelo emite basura que un clasificador ingenuo puntúa como cumplimiento. StrongREJECT sostiene, por tanto, que una fracción grande de las cifras de ASR de titular estaban infladas.

Del lado del **ataque**, el linaje va desde ataques de gradiente en caja blanca — **GCG** (Zou et al., 2023; 2307.15043), que introdujo AdvBench y sufijos adversarios transferibles — hasta atacantes de caja negra eficientes impulsados por LLM: **PAIR** (2310.08419, jailbreak en <20 consultas), **TAP** (2312.02119, árbol de ataques, >80% ASR en modelos clase GPT-4) y **Rainbow Teaming** (2402.16822), que plantea la generación de prompts adversarios como búsqueda de calidad-diversidad.

Los resultados **multi-turno** de 2024 son, posiblemente, el desarrollo más importante para los profesionales. **Crescendo** de Microsoft (2404.01833) parte de una pregunta benigna y escala gradualmente, guiando al modelo con sus propias respuestas previas hasta alcanzar un ASR alto en ChatGPT, Gemini y modelos Llama. El estudio de **Multi-turn Human Jailbreaks (MHJ)** de Scale AI (2408.15221) es la prueba definitiva: red-teamers humanos alcanzaron >70% de ASR en HarmBench contra defensas que reportan un ASR de un solo dígito bajo ataques automatizados de un turno, e incluso recuperaron conocimiento de doble uso «desaprendido». El **Many-shot Jailbreaking** de Anthropic (página de investigación; actas de NeurIPS 2024) muestra que la eficacia escala como una *ley de potencias* en el número de ejemplos de falso cumplimiento en contexto — una vulnerabilidad creada por las mismas ventanas de contexto largas que hacen útiles a los modelos.

2.3 Hallazgos recientes y vacíos de investigación reconocidos

Tres hallazgos reaparecen en la literatura 2024–2026:

1. **Los modelos frontera siguen siendo no robustos ante ataques adaptativos.** Andriushchenko et al. (ICLR 2025; 2404.02151) alcanzan ~100% de ASR en muchos modelos alineados con ataques adaptativos simples por modelo, y muestran de forma crucial que el ASR es *muy sensible al presupuesto de ataque, la elección del juez y la definición de una cadena objetivo exitosa* — es decir, no es un número único estable.

2. **La evaluación de un turno subestima sistemáticamente el riesgo desplegado** (MHJ, Crescendo, M2S 2503.04856). Las salvaguardas ajustadas al inglés de un turno colapsan bajo presión multi-turno e interlingüe (2504.03174).
3. **La alineación puede ocultar los problemas en lugar de eliminarlos** (la brecha encubierto/manifiesto de Hofmann et al.).

Los vacíos que los propios autores reconocen son notablemente consistentes: (a) **no hay una definición o taxonomía acordada de «daño»** (Ganguli et al., 2209.07858); (b) la cobertura es abrumadoramente **en inglés, solo texto y de un turno**, dejando infra-evaluados los escenarios multilingües, multimodales y agénticos; (c) las **evaluaciones son cotas inferiores** — pueden demostrar una capacidad pero nunca probar su ausencia (Phuong et al., 2403.13793; 2412.08653); y (d) los **jueces y métricas están, ellos mismos, sin validar** (sección 3.3).

3. Metodologías: cómo se hace esto en la práctica

3.1 Red-teaming humano vs. automatizado

El **red-teaming humano** — evaluadores expertos sondeando el modelo — sigue siendo el patrón de oro para *descubrir* modos de fallo novedosos. El estudio fundacional es Ganguli et al. (Anthropic, 2022; 2209.07858), que publicó ~39k ataques humanos y halló que los modelos con RLHF se vuelven más difíciles de atacar con la escala. Sus debilidades reconocidas definen el compromiso: el red-teaming humano es **caro, lento, difícil de reproducir, dependiente de la identidad y creatividad del evaluador** y conlleva un **coste psicológico** real para quienes se exponen a contenido perturbador.

El **red-teaming automatizado** usa un modelo para atacar a otro. El trabajo seminal es Perez et al. (DeepMind, 2022; 2202.03286), «Red Teaming Language Models with Language Models». Los métodos automatizados escalan y se reproducen a bajo coste, pero sufren **colapso de modos** — redescubren un puñado de plantillas de ataque —, razón por la que existen métodos que buscan *diversidad* como el red-teaming impulsado por curiosidad (2402.19464) y Rainbow Teaming. En la práctica, los programas maduros (las evaluaciones holísticas de DeepMind, 2404.14068; las baterías de capacidades peligrosas de frontera, 2403.13793) **combinan ambos**: métodos automatizados para amplitud y regresión, humanos para profundidad y novedad.

3.2 Un turno vs. multi-turno; estático vs. dinámico

- **Benchmarks de un turno / estáticos** (HarmBench, JailbreakBench, BBQ) son baratos, comparables y reproducibles — y sistemáticamente optimistas. Se entienden mejor como *pruebas de regresión*, no como estimaciones de riesgo.
- **Evaluación multi-turno / dinámica** (Crescendo, MHJ) refleja el uso real y revela un riesgo mucho mayor, pero es cara y más difícil de estandarizar. Una revisión de la evaluación de agentes (2503.16416) reporta que solo ~2% de los estudios usan metodología más allá de casos de prueba fijos — un desequilibrio llamativo dado que los sistemas desplegados son agénticos y conversacionales.
- **Los benchmarks estáticos sufren además contaminación y saturación**: los conjuntos de prueba extraídos de la web se filtran en los datos de entrenamiento (2406.04244) y los leaderboards pueden manipularse. *The Leaderboard Illusion* (2504.20879) documenta asimetría de acceso a datos y pruebas privadas no reveladas en Chatbot Arena; un artículo complementario (2501.17858) demuestra manipulación descarada de votos.

3.3 Métricas y sus limitaciones

- **Attack Success Rate (ASR)** — la fracción de intentos que provocan una violación de política. Es el caballo de batalla del campo y su número más traicionero: depende del conjunto de ataques, del presupuesto de consultas y de *cómo se juzga un «éxito»* (2404.02151).
 - **Severidad / puntuación de daño** — ponderar las violaciones por el daño potencial (p. ej., una receta de bioarma » una grosería leve). La severidad es más relevante para la decisión que el ASR bruto, pero es subjetiva y rara vez está estandarizada.
 - **Tasa de rechazo** — con qué frecuencia el modelo declina. Confunde la *seguridad genuina* con el *rechazo excesivo* (un coste de utilidad) y es trivialmente manipulable por un modelo que lo rechaza todo.
 - **LLM-como-juez** — usar un LLM para puntuar salidas es hoy omnipresente porque el juicio humano no escala. Es también el punto débil del campo. La revisión de LLM-como-juez (2411.16594) cataloga sesgos de posición, verbosidad y auto-preferencia, y susceptibilidad a inyección de prompts; y *A Coin Flip for Safety* (2603.06594) halla que los jueces LLM rinden **cerca del azar** al decidir si un ataque adversario tuvo éxito. **Si el juez es un lanzamiento de moneda, todo ASR construido sobre él hereda ese ruido.** Por tanto, cualquier protocolo serio debe reportar la concordancia humano-juez y tratar las puntuaciones automáticas como estimaciones con barras de error.
-

4. Herramientas disponibles en el mercado

Herramienta	Tipo	Qué mide	Cómo se usa	Puntual vs. CI/CD
NVIDIA garak	OSS (Apache-2.0)	Jailbreaks, inyección, toxicidad, fugas, alucinación (50+ sondas)	Escáner CLI en Python, cualquier modelo por API	Sobre todo puntual; scriptable
Microsoft PyRIT	OSS (MIT)	Red-teaming automatizado + humano; multi-turno (Crescendo, TAP, Skeleton Key)	Framework Python + GUI CoPyRIT	Ambos; diseñado para escala
promptfoo	OSS (MIT)	50+ plugins de ataque; mapeos OWASP LLM Top-10, MITRE ATLAS	YAML declarativo, CLI/librería	CI/CD fuerte + puntual
Giskard	OSS + Hub comercial	Alucinación, inyección, toxicidad, robustez, sesgo; agentes multi-turno	SDK Python; el Hub añade programación	OSS puntual; Hub continuo
DeepEval	OSS (Apache-2.0)	50+ métricas incl. sesgo, toxicidad, fidelidad (estilo Pytest)	Tests unitarios en Python	Tests unitarios → CI nativo
Stanford HELM	OSS	Holístico: precisión, robustez, equidad, sesgo, toxicidad	Framework Python, leaderboards	Benchmarking puntual
UK AISI Inspect	OSS (MIT)	Evals de frontera: uso de herramientas, multi-turno, juicio por modelo; 200+ evals	Framework Python	Ambos; suites de eval serias
Meta Purple Llama / Llama Guard	OSS (pesos)	Clasificadores de seguridad de entrada/salida e inyección; CyberSecEval	Modelos guardián + benchmarks	Runtime + benchmarks
HuggingFace Evaluate	OSS (Apache-2.0)	Toxicidad, Regard, HONEST (estereotipo de género)	Librería Python	Puntual / integrable
Lakera Red / Guard	Comercial (Check Point)	Simulación de ataque pre-producción (Red); defensa runtime (Guard)	API SaaS	Red puntual; Guard continuo
Robust Intelligence	Comercial (Cisco AI Defense)	AI Validation (pre-despliegue) + AI Firewall (runtime)	Plataforma empresarial	Ambos
Google Perspective API	API gratuita (cierre 2026-12-31)	Toxicidad, ataque a identidad, insulto, amenaza	API REST	Por solicitud

Lectura práctica del panorama: un stack común de 2026 combina **garak** + **PyRIT** (descubrimiento ofensivo), **promptfoo** (barrera de regresión en CI/CD) y una **salvaguarda en runtime** (Llama Guard / Lakera Guard / RI Firewall). Nótese la **ola de consolidación** — promptfoo → OpenAI (2026), Lakera → Check Point (2025), Robust Intelligence → Cisco (2024) —, por lo que nombres de producto y URLs están migrando, y **Perspective API está siendo dado de baja**, así que no debería anclar nuevas tuberías de largo plazo. Ninguna herramienta única cubre bien el sesgo y los jailbreaks y la defensa en runtime; la composición es obligatoria.

5. Propuesta: cómo se podría abordar esta investigación

Lo que sigue es un diseño concreto y viable para un estudio original de *cómo se comportan los modelos actuales*, dimensionado para un equipo pequeño.

Modelos bajo prueba. Comparar 4–6 modelos que cubran el espacio de diseño: dos frontera propietarios (p. ej., un modelo clase Claude y uno clase GPT), dos de pesos abiertos potentes (p. ej., un Llama y un modelo clase Qwen/Mistral) y un modelo local pequeño como línea base. Fijar versiones exactas y parámetros de muestreo — el comportamiento cambia entre versiones.

Categorías prioritarias de daño/sesgo. Resistir la tentación de cubrirlo todo. Priorizar donde la evidencia dice que el riesgo es a la vez alto e infra-medido: (1) **sesgo dialectal encubierto** (el hallazgo reciente de mayor señal), (2) **sesgo socioeconómico interseccional**, (3) **escalamiento multi-turno** hacia un pequeño conjunto de objetivos claramente violatorios de política, y (4) **adulación/manipulación** como sonda de desalineación.

Mezcla benchmark + red-team propio. Usar los benchmarks existentes como *suelo reproducible* y añadir red-teaming propio para *realismo*: - *Sesgo*: BBQ + HolisticBias para amplitud; reproducir el Matched Guise Probing de Hofmann para sesgo dialectal encubierto; añadir escenarios interseccionales tipo SilverSpoon. - *Daño*: HarmBench/JailbreakBench de un turno como línea base de regresión; luego una **campaña multi-turno propia** usando Crescendo de PyRIT y un pequeño red-team humano sobre los mismos comportamientos objetivo — precisamente para medir la brecha un-turno-vs-multi-turno en modelos *actuales*. - *Puntuación*: usar el autograder de StrongREJECT y un segundo juez independiente, y **validar los jueces contra una muestra etiquetada por humanos**, reportando la concordancia (κ de Cohen). Nunca reportar un ASR sin la tasa de error de su juez.

Documentación e informe. Seguir las normas emergentes: publicar un **apéndice de model card / system card** por modelo; liberar prompts y (donde sea legal y seguro) artefactos como en JailbreakBench; reportar el ASR *con intervalos de confianza y presupuesto de consultas*, puntuaciones ponderadas por severidad, tasas de rechazo y de rechazo excesivo, y la brecha de sesgo encubierto–manifiesto. Enmarcar todos los números como **cotas inferiores**.

Recursos, tiempo y límites. Un estudio mínimo es factible en **~8–12 semanas** para 2–3 investigadores: ~2 semanas de arnés/herramientas (Inspect o PyRIT + promptfoo en CI), ~4–5 semanas ejecutando benchmarks y campañas de red-team, ~2 semanas de validación de jueces y análisis, ~2 semanas de redacción. Presupuestar **costes de API** (los ataques multi-turno multiplican el gasto de tokens) y tiempo de GPU para modelos de pesos abiertos. Las restricciones **éticas y técnicas** son de primer orden, no notas al pie: - **Doble uso.** No publicar *uplift* operativo (recetas funcionales de armas/ciberataque). Reportar la *existencia* de una vulnerabilidad y su severidad, no un exploit ejecutable; seguir **divulgación coordinada** con el proveedor del modelo, según la guía NIST AI 800-1. - **Cuidado de sujetos humanos.** Los red-teamers necesitan advertencias de contenido, rotación y apoyo psicológico. - **Validez de constructo.** Pre-registrar qué se *supone* que mide cada métrica y argumentar que es separable de la capacidad bruta (la crítica de «safetywashing», 2407.21792). - **Contaminación.** Preferir prompts de autoría nueva o perturbados; asumir que los benchmarks públicos pueden estar en los datos de entrenamiento.

6. Preguntas abiertas para un proyecto de investigación propio

1. **¿Podemos construir un juez fiable?** Dado que los jueces LLM puntúan la robustez adversaria cerca del azar (2603.06594), ¿qué protocolo de ensamble, calibración o humano-en-el-bucle convierte el ASR en un número fiable — y cómo lo certificamos?

2. **¿Cuál es el verdadero gradiente de riesgo un-turno → multi-turno → agéntico** en los modelos frontera de 2026, medido sobre comportamientos objetivo idénticos? MHJ estableció la brecha en modelos de 2024; ¿se está cerrando o ampliando a medida que crecen las ventanas de contexto y los andamiajes agénticos?
 3. **¿La alineación oculta el sesgo?** Hofmann et al. hallaron que el RLHF amplió la brecha encubierto–manifiesto. ¿Es esto general entre tipos de sesgo e idiomas, y puede una intervención reducir la brecha *encubierta* sin dañar la utilidad?
 4. **¿Cómo medimos el comportamiento sin una verdad de referencia en la que confiar?** ¿Cómo se vería en la práctica un benchmark de comportamiento con *validez de constructo*, resistente a la contaminación y regenerado dinámicamente (según 2511.04703)?
 5. **¿Predicen las cifras de benchmark el daño en el mundo real?** Hay poca evidencia que vincule el ASR o las puntuaciones de sesgo con incidentes reales. ¿Qué diseño longitudinal o de prueba de campo (cf. NIST ARIA) cerraría esa brecha?
 6. **Puntos ciegos multilingües y multimodales.** Las salvaguardas se degradan entre idiomas (2504.03174); ¿qué tamaño tiene la superficie de daño no-inglesa y no-textual en los modelos actuales, y quién soporta ese riesgo infra-medido?
-

Referencias seleccionadas

(Todos los PDF de arXiv están archivados en [state_of_art/](#); véase [state_of_art/SOURCES.md](#) para el índice completo, URLs de herramientas y documentos de gobernanza.)

- Parrish et al. (2022). *BBQ: A Hand-Built Bias Benchmark for QA*. arXiv:2110.08193.
- Dhamala et al. (2021). *BOLD*. arXiv:2101.11718. · Smith et al. (2022). *HolisticBias*. arXiv:2205.09209.
- Nadeem et al. (2020). *StereoSet*. arXiv:2004.09456. · Nangia et al. (2020). *CrowS-Pairs*. arXiv:2010.00133.
- Hofmann, Kalluri, Jurafsky, King (2024). *Dialect prejudice predicts AI decisions...* *Nature* 633. arXiv:2403.00742.
- Ziems et al. (2023). *Multi-VALUE*. arXiv:2212.08011. · Singh et al. (2024). *Born With a Silver Spoon?* arXiv:2403.14633.
- Arzaghi et al. (2024). *Intrinsic Socioeconomic Biases in LLMs*. AIES. arXiv:2405.18662.
- Gallegos et al. (2024). *Bias and Fairness in LLMs: A Survey*. *Computational Linguistics*. arXiv:2309.00770.
- Mazeika et al. (2024). *HarmBench*. ICML. arXiv:2402.04249. · Chao et al. (2024). *JailbreakBench*. arXiv:2404.01318.
- SORRY-Bench (2024). arXiv:2406.14598. · Souly et al. (2024). *StrongREJECT*. arXiv:2402.10260.
- Zou et al. (2023). *GCG / Universal Adversarial Attacks*. arXiv:2307.15043. · Chao et al. (2023). *PAIR*. arXiv:2310.08419.
- Mehrotra et al. (2023). *TAP*. arXiv:2312.02119. · Samvelyan et al. (2024). *Rainbow Teaming*. arXiv:2402.16822.
- Scale AI (2024). *Multi-turn Human Jailbreaks (MHJ)*. arXiv:2408.15221. · Russinovich et al. (2024). *Crescendo*. arXiv:2404.01833.
- Anthropic (2024). *Many-shot Jailbreaking*. anthropic.com/research/many-shot-jailbreaking; NeurIPS 2024.
- Andriushchenko et al. (2024). *Simple Adaptive Attacks*. ICLR 2025. arXiv:2404.02151.

- Perez et al. (2022). *Red Teaming LMs with LMs*. arXiv:2202.03286. · Ganguli et al. (2022). *Red Teaming to Reduce Harms*. arXiv:2209.07858.
- Phuong et al. (2024). *Evaluating Frontier Models for Dangerous Capabilities*. arXiv:2403.13793.
- Ren et al. (2024). *Safetywashing*. arXiv:2407.21792. · Bean et al. (2025). *Construct Validity in LLM Benchmarks*. arXiv:2511.04703.
- Li et al. (2024). *LLM-as-a-judge: A Survey*. arXiv:2411.16594. · *A Coin Flip for Safety* (2026). arXiv:2603.06594.
- Singh et al. (2025). *The Leaderboard Illusion*. arXiv:2504.20879. · Chang et al. (2023). *A Survey on Evaluation of LLMs*. arXiv:2307.03109.
- *What AI evaluations can and cannot do* (2024). arXiv:2412.08653. · *Benchmark Data Contamination: A Survey* (2024). arXiv:2406.04244.